BIOPOTENCIALES Y ADQUISICIÓN DE SEÑALES ECG Y EMG

Juliana Sarmiento Arciniegas y Valentina Restrepo

Profesora:

Marlen Sofia Muñoz Ruiz

Universidad de Antioquia

Facultad de Ingeniería

Bioingeniería

Medellín

2026

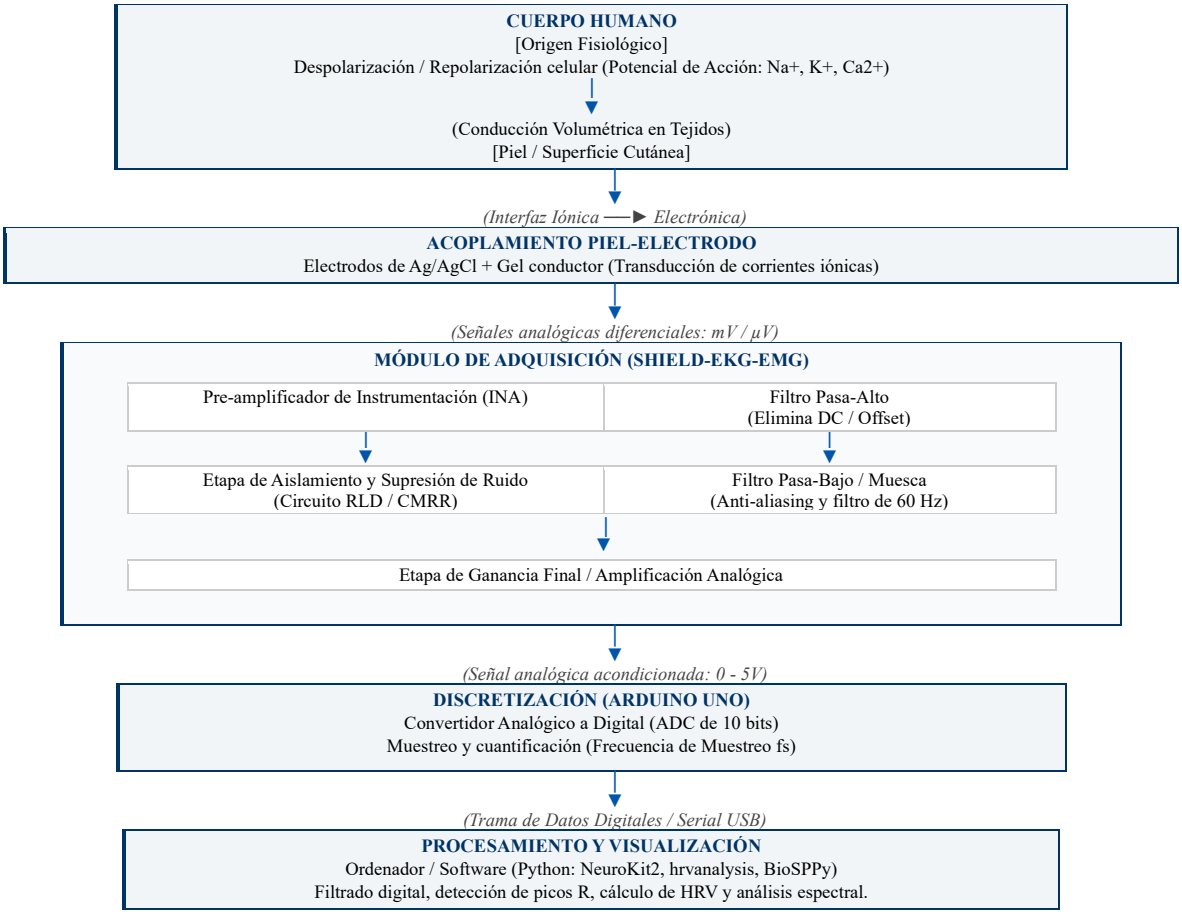
INTRODUCCIÓN

El estudio de los biopotenciales y las bioseñales es una pieza clave en la bioingeniería actual, ya que nos permite entender el funcionamiento del cuerpo humano y desarrollar tecnologías para el diagnóstico médico, el monitoreo constante de pacientes y la creación de dispositivos asistenciales. Señales como el electrocardiograma (ECG) y la electromiografía de superficie (sEMG) nacen directamente de la actividad electroquímica de nuestras células. Cada vez que el corazón se contrae o un músculo se mueve, las células excitables se despolarizan y repolarizan mediante el flujo de iones (Na^+, K^+, Ca^{2+}). Estas pequeñas corrientes viajan a través de los tejidos —que actúan como un medio conductor— hasta llegar a la superficie de la piel, donde podemos captarlas.

Sin embargo, registrar estas señales sobre la piel no es una tarea sencilla. Nos enfrentamos a amplitudes extremadamente pequeñas (de milivoltios en el ECG y de microvoltios en la sEMG) y a una gran cantidad de ruidos e interferencias. La resistencia propia de la piel, las variaciones de voltaje en la interfaz con el electrodo, el ruido de 60 Hz de la red eléctrica y los mismos movimientos del paciente pueden deformar la señal o esconder la información real.

Por eso, para obtener datos limpios y confiables, es imprescindible diseñar minuciosamente cada etapa del circuito de adquisición, utilizando preamplificadores diferenciales de alto CMRR, filtros analógicos y etapas de acondicionado de señal. En esta práctica de laboratorio exploramos este proceso de adquisición registrando señales de ECG y sEMG mediante el módulo SHIELD-EKG-EMG de Olimex, conectado a una tarjeta Arduino UNO para digitalizar la información a través de su convertidor analógico-digital (ADC). Con este montaje, nuestro objetivo principal es comprender a fondo cómo se procesan analógica y digitalmente los biopotenciales, probar diferentes estrategias para reducir el ruido y analizar de forma detallada la Variabilidad de la Frecuencia Cardíaca (HRV) en el dominio del tiempo utilizando herramientas de procesamiento de señales en Python.

1) Esquemático de adquisición de biopotenciales (ECG / EMG):



2) Fuentes de ruido en el Registro de Biopotenciales:

Justificación Teórica de la Clasificación Temporal:

1. Fuentes Variantes en el Tiempo: Presentan características dinámicas cuya amplitud y espectro de frecuencia fluctúan continuamente durante la medición. La interferencia de 60 Hz varía en amplitud y fase según el acoplamiento capacitivo del entorno (Winter & Webster, 1983), mientras que los artefactos de movimiento y el ruido muscular (EMG) son fenómenos aperiódicos e impredecibles generados por variaciones en la piel o temblores involuntarios (Huigen et al., 2002; Friesen et al., 1990).
2. 2. Fuentes Estáticas (o Cuasi-estáticas): Exhiben un comportamiento relativamente constante una vez estabilizado el sistema de medida. El potencial de offset DC permanece continuo una vez alcanzado el equilibrio electroquímico en la interfaz piel-electrodo, mientras que el ruido térmico interno de los componentes electrónicos responde a procesos estocásticos estacionarios con varianza constante (Webster, 2009).

Fuente de Ruido	Naturaleza / Origen	Clasificación Temporal	Estrategias de Control / Eliminación
Interferencia de la red eléctrica (50/60 Hz)	Acoplamiento capacitivo e inductivo del entorno hacia los cables del paciente y el circuito.	**Variante en el tiempo** (Oscilatoria periódica)	• Uso del circuito de Pierna Derecha Impulsada (RLD). • Cables apantallados / trenzados. • Alto CMRR en el amplificador de instrumentación. • Filtro muesca (Notch filter) centrado en 50/60 Hz.
Artefactos por movimiento (Piel-Electrodo y Cable)	Desplazamiento relativo entre electrodo y piel (deformación de la capa córnea) o movimiento del cable.	**Variante en el tiempo** (Aperiódica y estocástica)	• Limpieza adecuada de la piel con alcohol (reducción de capa córnea). • Fijación física con cinta o bandas elásticas. • Electrodo no polarizable (Ag/AgCl) con gel conductor. • Filtro pasa-alto analógico/digital (>0.5 Hz en ECG, >10-20 Hz en EMG).
Interferencia Electromiográfica (EMG en registro de ECG)	Contracción involuntaria o temblor del músculo esquelético adyacente.	**Variante en el tiempo** (Estocástica de banda ancha)	• Reposo físico y postura cómoda del sujeto durante la toma. • Ubicación adecuada de electrodos lejos de masas musculares activas. • Filtrado adaptativo en procesamiento digital.
Offset por Potencial de Contacto (DC)	Potencial de media celda generado en la interfaz electroquímica electrodo-electrolito.	**Estática** (o de variación extremadamente lenta)	• Empleo de electrodos no polarizables de Ag/AgCl. • Desacoplo por condensador o etapa de filtrado pasa-alto en el preamplificador.
Ruido Térmico y de Semiconductor (Johnson-Nyquist / Shot)	Agitación térmica de portadores de carga y transiciones de corriente en componentes.	**Estática** (Proceso estocástico estacionario)	• Selección de amplificadores operacionales de bajo ruido. • Limitación del ancho de banda mediante filtros pasa-bajo al rango estrictamente fisiológico (Anti-aliasing).

3) Problemática y Relevancia del Acoplamiento Piel-Electrodo:

Problemática Asociada al Acoplamiento Piel-Electrodo:

El principal obstáculo es la estructura de la piel. El estrato córneo actúa como un dieléctrico con propiedades capacitivas y resistivas elevadas, lo que genera una alta impedancia de contacto que dificulta el paso de las microseñales hacia el amplificador, [6]. Al colocar un electrodo sobre la piel, se establece una transducción de corriente iónica (del cuerpo) a corriente electrónica (del metal), lo que genera un potencial de semicelda. Si el electrodo se desplaza mecánicamente o si hay transpiración, este potencial fluctúa drásticamente, provocando artefactos de movimiento e inestabilidades que pueden saturar las etapas de amplificación, [7]. Asimismo, una impedancia de contacto elevada y desbalanceada hace que el sistema sea altamente vulnerable al ruido de modo común (como la interferencia de la red eléctrica de 50/60 Hz).

Estrategias Utilizadas para Mejorarla

Para mitigar estos efectos, se emplean dos enfoques principales: la preparación de la zona y el desarrollo de nuevas tecnologías de sensores. Tradicionalmente, se realiza una abrasión mecánica suave para retirar las células muertas del estrato córneo, acompañada de una limpieza química con alcohol isopropílico para eliminar lípidos y sudor. Posteriormente, se aplican geles electrolíticos que penetran los poros disminuyendo drásticamente la resistencia de contacto.

En el ámbito tecnológico, se utilizan electrodos activos, los cuales incorporan un circuito preamplificador directamente sobre el sitio de registro para anular el efecto de la impedancia de los cables conductores. De igual forma, el estado del arte incluye electrodos secos avanzados basados en microagujas que atraviesan el estrato córneo sin dolor, así como electrodos textiles y parches flexibles (tatuajes electrónicos) fabricados con nanomateriales como el grafeno, los cuales se adaptan de forma óptima a la microgeometría de la piel, reduciendo drásticamente el movimiento relativo, [9].

Por qué es la etapa más crítica en sEMG, EEG y ECG

El acoplamiento constituye la etapa más crítica porque determina de forma irreversible la relación señal-ruido (SNR) de todo el sistema. Las señales de superficie poseen amplitudes extremadamente bajas (las ondas de EEG rondan los 10–100 μV, mientras que el sEMG y ECG oscilan en el rango de los milivoltios), [6]. Si la interfaz introduce ruido térmico o artefactos de gran magnitud debido a un mal acoplamiento, la señal biológica útil se atenúa o se enmascara por completo. Debido al principio de ingeniería de "basura entra, basura sale", si la información se corrompe en este punto de contacto físico, ningún filtro digital o algoritmo posterior de procesamiento de señales podrá recuperar los datos perdidos, [8].

4) Análisis de la Variabilidad de la frecuencia cardíaca (HRV):

Metodología del Código para la Sección

Para abordar esta sección, desarrollamos un script en Python diseñado para procesar la señal electrocardiográfica del archivo datosECG1.txt (registrada a una frecuencia de muestreo $f_s = 100Hz$ y evaluar el desempeño de dos algoritmos de detección del complejo QRS frente al cálculo de la variabilidad de la frecuencia cardíaca (HRV).

El flujo de trabajo computacional se estructuró en tres etapas clave:

1. Acondicionamiento y detección adaptativa con NeuroKit2: En la primera aproximación, utilizamos la función nk.ecg_clean() para preprocesar la señal. Este paso fue fundamental debido a que el registro presentaba un offset DC de $+1.51$ V introducido por el sistema de adquisición analógico. Al aplicar un filtro pasa-banda digital, logramos remover esta componente continua y suprimir el ruido de alta frecuencia, dejando la línea base perfectamente centrada en cero. Posteriormente, la función nk.ecg_peaks() identificó las cúspides de las ondas R aplicando un algoritmo de umbral adaptativo sobre la señal limpia [10].

2. Detección directa con Detectors (Pan-Tompkins): Para poner a prueba la robustez de los algoritmos clásicos frente a datos no acondicionados, empleamos la librería ecgdetectors e instanciamos la función pan_tompkins_detector(). A diferencia de la primera etapa, este método se ejecutó directamente sobre la señal en bruto, sin sustraer el offset de 1.51 V ni aplicar prefiltrado. El objetivo de este diseño fue observar experimentalmente cómo la ausencia de desacoplo DC desajusta el integrador y los umbrales de decisión del algoritmo original de Pan-Tompkins [11].

3. Conversión a intervalos R-R y extracción de métricas HRV con hrvanalysis: Una vez obtenidos los índices de muestreo de los picos R (R_i), calculamos la serie temporal de diferencias entre latidos consecutivos en milisegundos:

$$\Delta RR_i = \frac{R_{i+1} - R_i}{f_s} \times 1000 \quad [\text{ms}]$$

Finalmente, ingresamos esta serie de intervalos a la función get_time_domain_features() del paquete hrv-analysis. Esta rutina procesó los tiempos transcurridos entre picos R para extraer los parámetros estadísticos estándar en el dominio del tiempo (mean_nni, sdnn, rmssd, pnni_50 y nni_50), permitiendo evaluar la modulación autonómica y parasimpática bajo los criterios clínicos internacionales establecidos por la Task Force [12].

Resultados obtenidos del código:

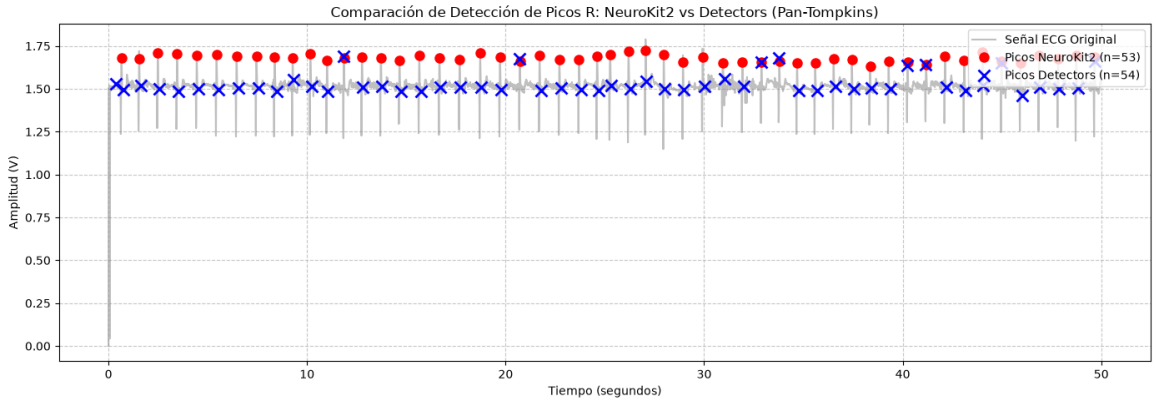


Fig.1 Resultado del análisis del ECG

Al observar la gráfica de la Fig.1, salta a la vista una diferencia clara entre ambos métodos:

- NeuroKit2 (círculos rojos): Identifica sin problemas los 53 picos R reales del registro, ubicándose justo en las cúspides de mayor amplitud del complejo QRS (entre 1.65 V y 1.70 V).
- Detectors / Pan-Tompkins (cruces azules): Aunque marca 54 eventos, la gran mayoría están desplazados hacia abajo. Al procesar la señal directamente con el offset de 1.51 V, el algoritmo confunde el nivel isoeléctrico y la deflexión de la onda S con verdaderos picos R, acertando solo en unos pocos latidos aislados.

Esto confirma que NeuroKit2 ofrece un desempeño muy superior en esta prueba. El filtrado previo y la eliminación del offset continuo no son pasos opcionales, sino requisitos indispensables para que este tipo de algoritmos no confundan el ruido o la línea base con el complejo QRS.

Ahora para calcular la variabilidad de la frecuencia fue a partir de los 53 picos R identificados correctamente por NeuroKit2 a lo largo de los 50 segundos del registro, obtuvimos un intervalo R-R promedio de 961.5 ms, lo que equivale a una frecuencia cardíaca promedio de 62.4 BPM. Este valor refleja un ritmo sinusal regular, perfectamente normal para una persona en reposo (cuyo rango habitual está entre 60 y 70 BPM).

Al calcular los parámetros de variabilidad (HRV) con la librería hrvanalysis, obtuvimos varios indicadores estándar en cardiología. Sus nombres provienen de siglas en inglés, y su significado fisiológico se explica de forma sencilla a continuación:

- **mean_nni (**961.5 ms**): Promedio de tiempo entre latidos.**

Proviene de *Mean of Normal-to-Normal Intervals*. Se usa el término *NN* (normal a normal) en lugar de *RR* para garantizar que solo se están midiendo latidos limpios y reales. En la práctica, nos dice cada cuánto tiempo, en promedio, latía el corazón durante la prueba.

- **sdnn (**42.1 ms**): Variabilidad global del corazón.**

Viene de *Standard Deviation of NN Intervals*. Mide qué tanto cambian los intervalos entre latidos a lo largo de todo el registro. Al estar por encima del límite clínico normal (30 ms), demuestra que el sistema nervioso del sujeto responde bien y no hay rigidez en su ritmo cardíaco.

- **rmssd (**35.8 ms**): Cambios rápidos latido a latido (actividad del nervio vago).**

Significa *Root Mean Square of Successive Differences*. Evalúa las variaciones micro-temporales entre un latido y el siguiente. Es el indicador directo de la modulación parasimpática, responsable de mantener el cuerpo en estado de calma y recuperación.

- **nni_50 (**6**) y pnni_50 (**11.5 %**): Diferencias marcadas entre latidos.**

Corresponden a la cantidad y al porcentaje de latidos consecutivos que variaron en más de 50 ms entre sí (*Percentage of NN intervals > 50 ms*). Un valor del 11.5 % confirma que la respiración del sujeto está modulando suavemente su ritmo cardíaco, algo propio de una persona relajada.

Si hubiéramos trabajado con la detección errónea de Pan-Tompkins, estos valores habrían dado números completamente distorsionados. Esto demuestra lo indispensable que es limpiar y filtrar bien las bioseñales antes de calcular cualquier parámetro médico.

Función get_time_domain_features() de la librería hrvanalysis

La función get_time_domain_features() de la librería hrvanalysis se utiliza para calcular diferentes características de la variabilidad de la frecuencia cardíaca (HRV) en el dominio del tiempo. Para esto, toma como entrada los intervalos NN, que corresponden al tiempo transcurrido entre dos latidos normales consecutivos.

Entre los parámetros que calcula se encuentran la media de los intervalos NN (Mean_NN), su desviación estándar (SDNN), la raíz cuadrada de la media de las diferencias sucesivas al cuadrado (RMSSD) y el porcentaje de diferencias entre intervalos consecutivos mayores a 50 ms (pNN50). También permite obtener valores de frecuencia cardíaca promedio, mínima y máxima.

Estas medidas permiten conocer qué tanto varía el tiempo entre los latidos del corazón y describir el comportamiento de la frecuencia cardíaca a lo largo del registro. De esta manera, la función facilita el análisis de la HRV a partir de los datos obtenidos de una señal ECG.

5) Aplicaciones clínicas de ECG y EMG:

Aplicaciones del ECG:

- Diagnóstico de arritmias (Holter): Detecta alteraciones del ritmo y la frecuencia cardíaca a lo largo del día, usa registro continuo ambulatorio y su procesamiento utiliza algoritmos de detección de complejos QRS a largo plazo para evaluar la irregularidad del ritmo.
- Detección de isquemia miocárdica: Identifica zonas del corazón que reciben impulsos eléctricos de forma anormal o insuficiente, emplea un registro de derivaciones superficiales en reposo y su procesamiento se basa en el promediado de señales para analizar variaciones morfológicas.
- Prueba de esfuerzo (Ergometría): Evalúa la actividad eléctrica del corazón bajo exigencia física, emplea un registro dinámico superficial y su procesamiento exige la implementación de filtros adaptativos rigurosos para suprimir los fuertes artefactos de movimiento.

Aplicaciones del EMG:

- Diagnóstico de neuropatías y miopatías: Evalúa el estado de las fibras nerviosas motoras y musculares, requiere un registro invasivo mediante agujas insertadas en el músculo y su procesamiento implica aislar y analizar la morfología de los potenciales de acción de unidad motora.

- Control de prótesis mioeléctricas: Traduce la intención de movimiento del usuario para accionar extremidades robóticas, utiliza un registro no invasivo de electromiografía de superficie y su procesamiento extrae características de la señal aplicando algoritmos de clasificación de patrones.

- Rehabilitación y biofeedback: Permite al paciente visualizar su propia actividad muscular en tiempo real para recuperar movilidad, emplea un registro de electromiografía de superficie y su procesamiento aplica rectificación y filtrado pasa-bajo para generar indicadores visuales o sonoros.

Conclusiones:

- La actividad electroquímica de las membranas de las células excitables genera corrientes iónicas que se propagan a través de los tejidos hasta la superficie de la piel, dando origen a biopotenciales de baja amplitud. Estas señales contienen información importante sobre la actividad cardiovascular y neuromuscular, que puede estudiarse mediante registros ECG y EMG.

- El acoplamiento piel-electrodo es una de las etapas más importantes en la adquisición de biopotenciales superficiales, debido a que una impedancia de contacto elevada o inestable puede atenuar la señal fisiológica y favorecer la aparición de artefactos de movimiento e interferencias, afectando la calidad del registro.

- El acondicionamiento analógico de las señales es fundamental para obtener registros confiables, ya que permite amplificar los biopotenciales y reducir las interferencias presentes durante la adquisición mediante amplificadores de instrumentación, circuitos de rechazo de modo común y filtros adecuados.

- La calidad de las señales adquiridas influye directamente en la confiabilidad de los análisis posteriores y en sus posibles aplicaciones biomédicas. Por esta razón, es necesario controlar

las fuentes de ruido y garantizar una adecuada preparación de la piel, colocación de electrodos y configuración del sistema de adquisición.

- El estudio comparativo demostró que el preprocesamiento digital es un paso indispensable antes de aplicar cualquier algoritmo de detección. La presencia del offset DC de +1.51 V desajustó por completo los umbrales adaptativos del algoritmo de Pan-Tompkins directo, provocando que marcara falsos picos en el nivel isoeléctrico. En contraste, la etapa de filtrado y centrado de línea base implementada por NeuroKit2 permitió identificar con total precisión los 53 picos R reales del registro. Esto evidencia que, en la ingeniería biomédica, la confiabilidad de los algoritmos de detección depende directamente de la calidad del acondicionamiento previo de la bioseñal.
- A partir de la detección exacta de las ondas R, el análisis de HRV en el dominio del tiempo con hrvanalysis arrojó indicadores clínicamente coherentes que confirman el buen estado autonómico del sujeto.

REFERENCIAS:

1. B. B. Winter en J. G. Webster, "Driven-right-leg circuit design," *IEEE Transactions on Biomedical Engineering*, vol. BME-30, no. 1, pp. 62–66, jan. 1983, doi: 10.1109/TBME.1983.325168. Disponible en: https://doi.org/10.1109/TBME.1983.325168
2. E. Huigen, A. Peper en C. A. Grimbergen, "Investigation into the origin of motion artifacts in skin-electrode data acquisition," *IEEE Transactions on Biomedical Engineering*, vol. 49, no. 7, pp. 670–674, jul. 2002, doi: 10.1109/TBME.2002.1013727. Disponible en: https://doi.org/10.1109/TBME.2002.1013727
3. G. M. Friesen *et al.*, "A comparison of the noise sensitivity of nine QRS detection algorithms," *IEEE Transactions on Biomedical Engineering*, vol. 37, no. 1, pp. 85–98, jan. 1990, doi: 10.1109/10.43620. Disponible en: https://doi.org/10.1109/10.43620
4. J. G. Webster, Ed., *Medical Instrumentation: Application and Design*, 4th ed. Hoboken, NJ, USA: John Wiley & Sons, 2009.
5. J. G. Webster, Ed., *Medical Instrumentation: Application and Design*, 4th ed. Hoboken, NJ, USA: John Wiley & Sons, 2009. [En línea]. Disponible en: Scribd
6. J. D. Bronzino, Ed., *The Biomedical Engineering Handbook*, 3rd ed. Boca Raton, FL, USA: CRC Press, 2006. [En línea]. Disponible en: ScienceDirect
7. Y. M. Chi, T.-P. Jung, y G. Cauwenberghs, "Dry-contact and noncontact biopotential electrodes: Methodological review," *IEEE Reviews in Biomedical Engineering*, vol. 3, pp. 106–119, 2010. [En línea]. Disponible en: IEEE Xplore / UANL
8. Analog Devices, "Biopotential Electrode Sensors in ECG/EEG/EMG Systems," *Analog Devices Technical Article*, 2008. [En línea]. Disponible en: Analog Devices
9. M. Alizadeh-Meghrazi *et al.*, "Materials, Devices, and Systems of On-Skin Electrodes for Health Monitoring and Human-Machine Interfaces," *PubMed Central (PMC)*, 2020. [En línea]. Disponible en: NCBI PMC

10. [1] D. Makowski *et al.*, "NeuroKit2: A Python toolbox for neurophysiological signal processing," *Behavior Research Methods*, vol. 53, no. 4, pp. 1689–1696, Aug. 2021. Disponible en: https://doi.org/10.3758/s13428-020-01516-y
11. [2] J. Pan and W. J. Tompkins, "A real-time QRS detection algorithm," *IEEE Transactions on Biomedical Engineering*, vol. BME-32, no. 3, pp. 230–236, Mar. 1985. Disponible en: https://www.academia.edu/26081423/A_REAL_TIME_QRS_DETECTION_ALGORITHM
12. [3] A. Champseix *et al.*, "hrv-analysis: A Python library for Heart Rate Variability analysis," *PyPI Repository*, 2018. Disponible en: https://pypi.org/project/hrv-analysis/
13. J. Pan y W. J. Tompkins, "A real-time QRS detection algorithm," *IEEE Transactions on Biomedical Engineering*, vol. BME-32, no. 3, pp. 230-236, 1985
14. H. Sotaquirá, "Electrocardiogram Signals Classification Using Deep Learning and Wavelet Transform Domains," *MDPI Computers*, vol. 13, no. 2, p. 55, 2024. Disponible de forma gratuita en: https://www.mdpi.com/2073-431x/13/2/55
15. J. Zhang et al., "Deep Learning for Personalized Electrocardiogram Diagnosis," *arXiv preprint arXiv:2409.07975*, 2024. Disponible de forma gratuita en: arxiv.org
16. M. S. Gaso, S. Cankurt, and A. Subasi, "Electromyography Signal Classification Using Deep Learning," *arXiv preprint arXiv:2305.04006*, 2023. Disponible de forma gratuita en: https://arxiv.org/abs/2305.04006
17. X. Zhong et al., "Deep Feature Learning for Processing Electromyographic Signals," *Edinburgh Research Explorer / IEEE*, pp. 1-12, 2025. Disponible de forma gratuita en: https://www.pure.ed.ac.uk/ws/portalfiles/portal/636179720/ZhongEtalIEEETNSRE2025DeepFeatureLearning.pdf
18. C. J. De Luca, "The Use of Surface Electromyography in Biomechanics," *Journal of Applied Biomechanics*, vol. 13, no. 2, pp. 135-163, 1997. Disponible de forma gratuita en: https://www.bu.edu/nmrc/files/2010/04/078.pdf